



Trackvance Core

Especificación técnica v1.1

IMPLEMENTACIÓN 0.4.1 · EVOLUCIÓN FUNCIONAL LOCAL

21 septiembre 2026 · Estado funcional y evidencia de validación

Arquitectura local y evolución a producto

Monolito modular · Persistencia local · Reglas portables · Evidencia verificable

Documento oficial de referencia. Describe el estado real de Trackvance Core y distingue las capacidades implementadas de los contratos preparados y la infraestructura objetivo.

Trackvance Colombia SAS

Contenido

1. Alcance, estados e invariantes	3
2. Arquitectura lógica estable	4
3. Despliegue local de referencia	5
4. Código, stack y dependencias	6
5. Fuentes y lectores de datasets	7
5A. Módulo Conexiones	8
6. Carga, esquema y versionado	9
7. Profiling, identificadores y transforms	10
8. Reglas portables y Data Intake	11
9. ReconOps y normalización declarada	12
10. Sentinel y métricas históricas	14
11. Excepciones con validación técnica	15
12. Centro de Control y navegación	16
13. StorageProvider, artefactos y linaje	17
14. Manifest schema 2 y auditoría	18
15. Reportes Excel de negocio	19
16. Ejecución, planificación y recuperación	19
17. Modelo persistente y migraciones	20
18. API y errores	21
19. Contratos HTTP y permisos	24
20. Configuración, operación y respaldo	25
20A. Benchmark reproducible y límites comprobados	27
21. Arquitectura final de producto	28
22. Calidad, pruebas y aceptación	29
23. Decisiones vigentes y control documental	32

1. Alcance, estados e invariantes

Trackvance Core es una plataforma local de confiabilidad de datos. Integra Data Intake, ReconOps y Sentinel con Datasets, Excepciones, Centro de Control, Auditoría e Identidad/RBAC. El usuario carga o versiona datos, publica una configuración inmutable, ejecuta controles y conserva evidencia verificable del resultado.

Esta especificación describe la evolución funcional local 0.4.1: conserva las capacidades 0.4.0 y mejora la configuración guiada por el esquema en Datasets, Data Intake, ReconOps y Sentinel, además del cierre de sesión. Conexiones PostgreSQL/SQL Server, reglas avanzadas, conciliación, programación Sentinel, excepciones, identidad, operación, recuperación y benchmarks mantienen su semántica certificada. El documento y la versión del software tienen ciclos distintos: se conserva el nombre v1.1 solicitado. Los resultados incrementales de esta revisión se registran en la sección de aceptación; no se extrapolan los de versiones anteriores.

Estado	Significado normativo
IMPLEMENTADO	Existe en el código local y en el flujo operativo, con cobertura automatizada o evidencia ejecutada.
PREPARADO	Existe un puerto, contrato versionado o rechazo controlado. El adaptador productivo todavía requiere implementación y validación.
OBJETIVO	Forma parte de la arquitectura final prevista; no es una dependencia ni capacidad operativa de la instalación local.

Invariantes compartidos


- La arquitectura lógica es un monolito modular. API y workers pueden desplegarse como procesos separados del mismo producto; no son microservicios de negocio.
- PostgreSQL guarda metadata y relaciones. Los archivos recibidos, Parquet canónicos, resultados, manifiestos y exports se guardan fuera de PostgreSQL.
- DatasetVersion, configuración publicada y Run conservan identidades estables. Una modificación funcional crea una versión o ejecución nueva.
- SUCCESS significa que terminó el procesamiento. REJECTED, WITH_FINDINGS y ALERT son decisiones de negocio y no errores técnicos.
- Profiling observa los valores recibidos sin trim, case o normalización Unicode funcional implícita. Las transformaciones de negocio deben estar declaradas.
- Toda modificación del esquema persistente se realiza mediante una migración Alembic nueva. No se editan migraciones ya aplicadas.
- La autorización por rol, permiso y organización se verifica en backend; ocultar un botón no sustituye la autorización.
- El prototipo funciona localmente con imágenes preparadas. No necesita servicios cloud para operar.

Qué no se certifica como implementado

PySpark operativo, Redis/Celery productivo, conectores distintos de PostgreSQL/SQL Server, object storage remoto, OIDC/SSO, Kubernetes, Terraform, Helm, observabilidad distribuida, masking por sensibilidad y escalamiento de producción pertenecen a los estados PREPARADO u OBJETIVO. Data Delivery/DataSink es una responsabilidad futura independiente de las entradas. El roadmap oficial completa primero los puntos funcionales 1 a 9; la productización del punto 10 requiere una evolución posterior y no forma parte de este ciclo.

2. Arquitectura lógica estable

La separación principal es entre adquisición de datos, almacenamiento interno y ejecución. Estos conceptos tienen responsabilidades y credenciales distintas. Leer un archivo de un bucket del cliente no implica almacenar los artefactos internos en ese mismo bucket.



Puerto / componente	Responsabilidad	Adaptador local
DatasetSource	Adquirir datos desde una fuente y devolver el modelo común.	Archivos locales, PostgreSQL y SQL Server
SecretStore	Gestionar credenciales por organización, fuera de artifacts.	Cifrado Fernet local, clave separada
DatasetReader	Interpretar un formato de archivo y sus opciones de lectura.	CSV, XLSX, JSON, Parquet, TXT
StorageProvider	Publicar bytes inmutables, materializar un artefacto y asignar staging temporal.	FileArtifactStore
ExecutionEngine	Ejecutar un Run completo con evidencia y linaje.	LocalExecutionEngine
ProcessingEngine	Compilar/evaluar expresiones portables de reglas y comparaciones.	Polars; DuckDB para paridad cubierta
ExecutionPlanner	Estimar recursos y fijar un plan antes de ejecutar.	Presupuesto de memoria/disco local
JobQueue	Publicar el trabajo asociado a un Run.	DatabaseJobQueue
NotificationDelivery	Contrato para entregar una alerta fuera del sistema.	PREPARADO; las alertas actuales son Findings internos

Las reglas no reciben cadenas de conexión ni conocen CSV, Excel o buckets. Trabajan sobre el modelo común producido por los lectores y el Parquet canónico. La orquestación usa identidades de versiones y configuraciones, genera hallazgos y publica evidencia mediante los puertos.


Separación incremental

La implementación mantiene un paquete Python compacto. API, servicios, modelos ORM, reglas, adapters y worker están en módulos distintos, pero aún no existe una capa de dominio totalmente libre de ORM. ExecutionEngine y JobQueue reciben Session/Run de SQLAlchemy. Esta frontera es suficiente para sustituir infraestructura de forma progresiva; no se declara una arquitectura hexagonal pura ni una sustitución cloud inmediata sin trabajo adicional.

StorageProvider devuelve Path únicamente para staging/materialización necesarios por los motores locales. Los servicios no deciden el directorio del volumen. Los campos históricos *_path permanecen compatibles como referencias internas; una migración futura de locators debe preservar IDs, hashes y linaje.

3. Despliegue local de referencia

IMPLEMENTADO. Docker Compose es el entorno de referencia para operación y certificación con PostgreSQL. El arranque directo Windows/SQLite se conserva como comodidad de desarrollo y usa una instalación de datos independiente.



Servicio	Función	Persistencia / red
web	React compilado servido por nginx y proxy a /api.	Publicado solo en 127.0.0.1; puerto configurable.
api	FastAPI, sesión/RBAC, carga, configuración, consulta y downloads.	Red interna Compose; comparte trackvance_data.
worker	Despacha programación Sentinel y procesa jobs, leases y heartbeat del mismo monolito.	Red interna; comparte metadata y trackvance_data.
postgres	PostgreSQL 16 para metadata.	Volumen postgres_data; sin puerto publicado al host.

El volumen trackvance_data se monta en /var/lib/trackvance para API y worker. FileArtifactStore administra artifacts/<id>/data.<ext> y staging tmp; las rutas históricas permanecen legibles. No se guardan datasets como blobs SQL. Los volúmenes sobreviven a stop, restart, recreación de contenedores y docker compose down. down -v elimina volúmenes y no es un comando de actualización.

Solo API monta connection_credentials y connection_keys para adquirir fuentes externas. El worker monta únicamente trackvance_data: consume snapshots canónicos sin recuperar credenciales de conexión. La copia de recuperación debe conservar metadata, artifacts, credenciales cifradas y clave de forma coordinada.

Todos los servicios declaran restart: "no". Trackvance permanece detenido al iniciar Docker Desktop hasta que el usuario ejecute el arranque. La instancia del equipo usa trackvance-certification y http://localhost:3100; el valor por defecto del repositorio es 3000.

```
docker compose up --build -d --wait
docker compose stop
docker compose up -d --wait
docker compose ps
```

La preparación descarga imágenes y dependencias. Una vez construidas, la operación no requiere fuentes, storage, identidad ni procesamiento externos. El override de red interna aísla API/worker/PostgreSQL; la salida de nginx depende de Docker Desktop/firewall y no se presenta como aislamiento total del host.

4. Código, stack y dependencias

Capa	Implementación actual
Frontend	React 19, TypeScript, Vite, React Router, TanStack Query, Radix Dialog, Lucide y CSS propio.
HTTP / persistencia	FastAPI, Pydantic, SQLAlchemy 2, Alembic, psycopg y PostgreSQL 16.
Procesamiento	Polars/Python, Decimal, expresiones portables y compilador DuckDB.
Formatos / evidencia	openpyxl para XLSX, lectores locales, Parquet, JSON y SHA-256.
Pruebas	pytest, Ruff, Mypy, ESLint, TypeScript, Vitest, Testing Library y Playwright.
Reproducibilidad	backend/uv.lock, frontend/pnpm-lock.yaml, Dockerfiles y compose.yml.

Responsabilidades del backend

Archivo	Responsabilidad principal
api.py	DTOs HTTP, sesiones, autorización, errores y endpoints.
services.py	Casos de uso: versiones, runs, evidencia, hallazgos y validación de excepciones.
models.py / db.py	Modelo persistente y unidad de sesión SQLAlchemy.
processing.py / config_semantics.py	Semántica de perfil, reglas, normalización y resultados.
portable_engine.py / planner.py	Compilación portable, evaluación y preflight.
dataset_readers.py	DatasetSource, registry y lectores por formato.
connections_api.py / connections_service.py	Contratos HTTP, configuración versionada, bindings y adquisición de fuentes.
dataset_sources.py / credential_store.py	Adaptadores SQL de solo lectura y contrato/proveedor de secretos.
artifactstore.py	StorageProvider y adaptador local inmutable.
execution.py / jobqueue.py / worker.py	Puerto de ejecución, publicación, consumo y recuperación local.
manifests.py / exports.py	Compatibilidad de evidencia y reportes Excel.
permissions.py / audit_context.py	Política RBAC, actor y sanitización de metadata.
dashboard.py	Agregación operativa del Centro de Control.
scheduler.py / sentinel_api.py	Programaciones versionadas, ocurrencias, despacho local e histórico de series.
exceptions_api.py	Asignación, SLA, comentarios, adjuntos y gestión de casos con concurrencia optimista.
identity_api.py	Usuarios locales, roles, permisos efectivos, contraseñas y revocación de sesiones.
operations_common.py	Inventario e integridad compartidos por las herramientas de mantenimiento.

El frontend se organiza en app, components, features/datasets, features/connections, features/runs, features/identity y routes; comparte cliente HTTP, componentes visuales y queries. RuleBuilder, ComparisonBuilder y TransformBuilder utilizan esquema real; MonitorSchedulePanel gestiona programación e historia. La organización por bounded contexts/domain/application/infrastructure podrá profundizarse cuando el tamaño lo justifique. No se mueve código sin un beneficio funcional o de frontera concreto.

No forman parte del stack instalado React Hook Form, Zod, Tailwind, TanStack Table, Recharts, PyArrow ni PySpark. La documentación inicial que los proponía se interpreta como antecedente de diseño, no como inventario actual.

5. Fuentes y lectores de datasets

IMPLEMENTADO. `DataSource.read(options, inspect)` devuelve `DatasetReadResult`. `LocalFileDataSource` resuelve el lector en `DatasetReaderRegistry`. Cada lector interpreta el formato sin aplicar transformaciones de negocio.

`DatasetReadResult` contiene `frame`, `source_format`, `format_label`, `media_type`, `row_numbering`, `native_schema`, hojas/opción seleccionada, delimitador detectado, `row_count` y metadata acotada. El frame común representa escalares observados como `String/Null`. La metadata nativa informa la inferencia sin alterar la representación recibida.

Fuente local	Detección y comportamiento
CSV	UTF-8 con BOM opcional; coma/punto y coma conservan compatibilidad. Conserva líneas físicas, incluidos registros multilínea.
XLSX	Verifica paquete Excel, limita expansión y rechaza macros. Enumera hojas, permite seleccionar y usa lectura acotada. Las fórmulas se tratan como texto observado.
JSON	Arreglo de objetos, objeto individual, objeto con un único arreglo tabular y JSONL/NDJSON. Objetos anidados simples se aplanan con rutas de punto; listas internas permanecen JSON compacto.
Parquet	Usa esquema embebido y footer. Revisa filas, columnas y expansión antes de leer; la inspección no requiere decodificar todo el archivo.
TXT / TSV	Detección de coma, punto y coma, tabulación o barra vertical; permite fijar un carácter ASCII seguro.

La resolución usa firmas fuertes, contenido, extensión y detección delimitada cuando procede. MIME y extensión de descarga se derivan del formato verificado; un nombre engañoso no determina por sí solo el parser ni el tipo de descarga.

Límites locales

La carga admite por defecto 10 MiB, 100.000 filas y 100 columnas. La inspección previa usa hasta 100 registros y metadata embebida donde existe. Los lectores limitan expansiones XLSX/Parquet y tamaño de celdas. La inspección controla la muestra; la carga/perfil inicial completos siguen siendo síncronos y acotados.

Conectores externos

`PostgreSQLDataSource` y `SQLServerDataSource` están implementados. Resuelven credenciales mediante `SecretStore`, limitan consultas en origen, conservan metadata reproducible sin secretos y producen el modelo común. S3, Azure Blob, REST, Oracle, MySQL, Snowflake y Databricks son futuros adaptadores. La adquisición podrá ejecutarse en un job sin cambiar las reglas.

5A. Módulo Conexiones

IMPLEMENTADO. Permite crear, probar, editar, deshabilitar y eliminar lógicamente conexiones PostgreSQL y SQL Server. La conexión registra nombre, motor, host, puerto, base, usuario y opciones controladas. La contraseña se envía únicamente al guardar/probar y nunca vuelve en una respuesta. El formulario exige una prueba vigente y backend vuelve a verificar antes de guardar. La deshabilitación puede hacerse aunque la fuente esté caída.

Después de conectar, el usuario explora schemas, tablas y vistas accesibles. La vista previa muestra nombres, tipos nativos/lógicos, nulabilidad y hasta 100 registros. La detección del esquema usa catálogos; no escanea la tabla completa. Registrar la selección crea un Dataset, su binding de origen y una DatasetVersion canónica Parquet mediante StorageProvider. Los motores de calidad siguen leyendo versiones locales inmutables.

Límites de responsabilidad

El PostgreSQL interno guarda solo metadata del sistema. PostgreSQL/SQL Server externos son fuentes del usuario y tienen credenciales independientes. Ningún adaptador escribe filas en la fuente. No se recibe SQL arbitrario; se seleccionan identificadores previamente descubiertos y citados según el motor. PostgreSQL usa transacciones read-only. En SQL Server la intención read-only es informativa: es obligatorio usar una cuenta con permisos SELECT mínimos, sin permisos de escritura.

Las fuentes externas requieren acceso de red desde API. El overlay offline restringe esa salida; el Compose base permite conexión a fuentes accesibles, sin añadir dependencias cloud. Para fuentes en el PC bajo Docker Desktop puede usarse host.docker.internal. La configuración local conserva restart=no.

Representación y límites

El preview aplica LIMIT/TOP en origen; el snapshot lee por lotes de 100 hasta 100.000 filas, 100 columnas y 64 MiB de valores normalizados. Cada celda tiene límite de 64 KiB. Una fila adicional detecta el exceso y se rechaza la importación completa: nunca se guarda una muestra parcial como si fuera un dataset completo. Timeout configurable de conexión 1..15 segundos; consulta 1..60 segundos. La adquisición sigue siendo síncrona y acotada.

Los valores se conservan como texto/null: Decimal sin redondeo float, fechas ISO, Unicode y espacios originales. Los identificadores siguen la política id/*_id y permiten override. Los binarios son Base64. SQL Server timestamp se interpreta como rowversion; datetimeoffset se conserva como ISO con offset. El orden DATABASE_UNSPECIFIED depende del motor; SNAPSHOT_ROW es posición en el snapshot, no un número físico en la tabla externa.

Versiones y evidencia

La conexión tiene ID estable y revisión para concurrencia optimista. Cada edición crea ExternalConnectionVersion inmutable con hash de configuración y referencia opaca de credencial. Un binding conserva dataset, conexión, schema, tabla/vista y overrides. Actualizar desde fuente usa la configuración vigente y crea una versión nueva. Fallos de acceso no modifican versiones anteriores.

ingestion_metadata.source conserva connection_id, connection_version_id, connection_version, source_type, schema_name, object_name, object_kind, config_hash y captured_at. El linaje SOURCE_SNAPSHOT apunta a la revisión de conexión; REFRESH_OF apunta al snapshot anterior. Los manifests de runs incluyen la identidad de fuente de cada DatasetVersion. El run original y su hash permanecen inmutables aunque cambie la conexión.

SecretStore, permisos y auditoría

El contrato put/get/delete permite sustituir el proveedor local por Azure Key Vault, AWS Secrets Manager o HashiCorp Vault. La implementación local cifra con Fernet autenticado, vincula credencial a organización/referencia y persiste en connection_credentials; la clave maestra reside en connection_keys. En Linux los directorios son 0700 y archivos 0600; Windows directo hereda ACL del usuario. El backup debe proteger ambos volúmenes por separado del almacenamiento de artifacts. Una clave perdida no se reemplaza silenciosamente si ya existen secretos. Rotación automática de clave maestra permanece pendiente.

La contraseña guardada solo se reutiliza en pruebas o ediciones cuando host, puerto, base, usuario y modo TLS coinciden con la versión vigente. Cambiar cualquiera exige una contraseña explícita; su ausencia devuelve 422 PASSWORD_REQUIRED_FOR_ENDPOINT_CHANGE antes de contactar el destino. Nombre y timeouts pueden cambiar conservando el secreto. Esto impide redirigir una credencial guardada a otro servidor desde un formulario de edición.

Transporte cifrado por defecto: PostgreSQL `sslmode=require` y SQL Server `encryption=require`. PostgreSQL permite `verify-ca/verify-full` con CA configurada. Requerir cifrado no equivale a verificar identidad del servidor; la confianza de certificados debe administrarse en el driver. Los modos `disable/off` se reservan para pruebas locales. FreeTDS comparte timeouts a nivel proceso; el adaptador SQL Server serializa conexiones para evitar carreras.

RBAC separa `connections:read`, `connections:use` y `connections:manage`. Administradores y responsables de datos administran; Analista puede usar. Los roles de consulta solo ven metadata. Todas las rutas verifican organización. La auditoría registra creación, edición, prueba, preview, baja y adquisición con actor estable; nunca password, DSN ni filas de preview. Los errores de drivers se convierten a códigos controlados y mensajes constantes.

Fuentes futuras y Data Delivery

Un nuevo adaptador implementa `DatasetSource` y su normalización, registra opciones permitidas y aporta pruebas de permisos, límites, tipos y trazabilidad. Fuentes no SQL tendrán DTOs específicos, sin forzar el concepto de schema/tabla sobre buckets o APIs. El motor de calidad no cambia. Un futuro módulo Destinos / Data Delivery tendrá un puerto independiente de escritura, RBAC e idempotencia propios. `DatasetSource` no incorpora `write` ni entrega hacia sistemas externos.

6. Carga, esquema y versionado

El flujo previo a guardar una versión detecta formato, hoja/delimitador, columnas y tipos. El usuario puede corregir el tipo lógico o marcar identificadores. Los mismos controles se ofrecen al crear una versión de un dataset existente.

- Columnas identificadoras se selecciona únicamente desde el esquema inspeccionado, con opción Todos. Se eliminó la entrada redundante de nombres libres; cada selección conserva el override `STRING + IDENTIFIER`.
- Los tipos disponibles son `STRING`, `INT64`, `DECIMAL`, `DATE`, `TIMESTAMP` y `BOOLEAN`; un override explícito se valida contra los valores del archivo.
- El campo Área de negocio permite agregar un área nueva. El listado muestra origen entre Dataset y Área: Manual para carga, Data Intake para salida derivada.
- El listado combina búsqueda/filtro y orden ascendente/descendente por Área, Registros, Versiones, Estado y Última actualización.
- Un nombre ya usado en la organización devuelve `DATASET_NAME_EXISTS` y permite orientar al usuario hacia una versión nueva.

Secuencia persistente

1. La API escribe el upload en staging limitado del provider y detecta el lector.
2. El lector produce el modelo común; profiling valida inferencia/overrides.
3. `StorageProvider` conserva `ORIGINAL_UPLOAD` con hash, tamaño y MIME.
4. Se publica `CANONICAL_PARQUET` y se crea `DatasetVersion` inmutable con esquema, perfil e `ingestion_metadata`.
5. `ArtifactLink` registra relaciones y `AuditEvent` registra `DATASET_UPLOADED`. Los temporales del flujo normal se eliminan.

`DatasetVersion` conserva `dataset_id`, `version`, `filename`, `source_type`, SHA-256, `schema_hash`, filas/columnas, `profile_status`, `schema_json`, `profile`, `ingestion_metadata`, `parent_version_id`, `original_artifact_id`, `canonical_artifact_id` y `source_run_id`. `original_path/canonical_path` se conservan como metadata interna compatible, no se exponen como rutas del cliente.

`ingestion_metadata` incluye `reader.key/version`, `source_format`, `format_label`, `reader_options` efectivas, esquema nativo y política de numeración. Los históricos reciben un objeto vacío y siguen el adaptador compatible sin recalculer sus perfiles.

`GET /datasets/{id}/schema` usa por defecto el perfil persistido. `refresh=true` vuelve a leer el footer canónico y conserva tipos lógicos declarados; devuelve `scan_mode/scanned_rows` y no aplica transforms ni reescribe historia. El control SHA-256 puede leer bytes para integridad aunque no procese filas de negocio.

7. Profiling, identificadores y transforms

La política actual es EXACT_OBSERVED, metric_definition_version=2. No se recortan espacios, cambia case ni normaliza Unicode para contar valores distintos. "Cliente 12" y " Cliente 12 " son valores distintos; las diferencias de mayúsculas y de representación Unicode se conservan. Null y texto vacío tienen semánticas propias del lector y del perfil; no se equiparan mediante un trim implícito.

Inferencia inequívoca

DATE se infiere cuando los valores no nulos válidos cumplen YYYY-MM-DD y representan fechas reales. Una fecha inválida o una mezcla incompatible impide inferir DATE. TIMESTAMP exige su semántica ISO diferenciada, con zona explícita según las reglas portables; no se adivinan fechas ambiguas como 01/02/2026.

IDENTIFIER tiene prioridad sobre la interpretación como magnitud. Los nombres id y *_id activan una heurística documentada; el usuario puede confirmar/override el esquema. "001234567" conserva su cero inicial frente a "1234567". No se convierten universalmente todas las columnas numéricas a identificadores. El esquema nativo Parquet ayuda a inferir tipos, incluso con columnas nulas, pero no invalida el override explícito.

En la carga inicial y al crear una versión, el selector de identificadores muestra las columnas realmente inspeccionadas y permite elegir algunas o todas. La API continúa recibiendo los mismos overrides; no se crea una segunda fuente de nombres ni se reescriben los esquemas de versiones históricas.

Los perfiles incluyen conteos de nulos y distintos, tasas y razón de unicidad, además de método/versión. Las series históricas LEGACY_NORMALIZED/1 se mantienen separadas de EXACT_OBSERVED/2 para no comparar métricas semánticamente incompatibles.

Transformaciones funcionales

Intake y ReconOps admiten listas ordenadas de transforms {column,type,parameters}: trim, case, unicode_normalization, empty_to_null, id_padding, remove_characters, decimal_parse y date_parse. Recon mantiene listas independientes para origen y destino. Sólo se ejecutan cuando el contrato las declara. El upload original, Parquet de entrada y perfil histórico no se reescriben; los resultados conservan los parámetros efectivos.

La interfaz presenta esos mismos tipos con nombres funcionales: Eliminar espacios externos, Convertir mayúsculas/minúsculas, Normalizar texto Unicode, Convertir texto vacío en nulo, Completar identificador, Eliminar caracteres, Interpretar número decimal e Interpretar fecha. Cada elemento muestra una explicación y un ejemplo recalculado con sus parámetros. Un preview de hasta ocho valores reales aplica las transformaciones de la columna en el mismo orden del contrato y muestra Antes / Después. Los controles permiten hacer explícito ese orden. Un parseo decimal o de fecha inválido muestra "No se pudo interpretar; la transformación conservó el valor que recibió". Los pasos posteriores siguen ejecutándose en el orden declarado. La vista previa de fechas cubre únicamente las directivas determinísticas que el navegador reproduce con certeza. Para formatos Python no soportados —por ejemplo %b, %j o %Z— muestra "Vista previa no disponible para este formato; la ejecución usará el formato declarado", sin convertir esa limitación en un fallo. datetime.strptime del backend conserva la autoridad sobre la ejecución. La vista previa se calcula sólo para informar: no crea artifacts, no modifica el

DatasetVersion y no forma parte del resultado ni del hash de configuración.

Las configuraciones nuevas se validan y normalizan a `schema_version=2`. `configuration_hash` usa JSON determinista con claves ordenadas y SHA-256; `stored_config_hash` conserva además la identidad de la configuración almacenada. La adaptación legacy se centraliza en `config_semantics` y manifests, evitando condiciones de versión dispersas en módulos.

8. Reglas portables y Data Intake

RuleDefinition declara `type`, `column` o `columns` en `parameters`, `severity` ERROR/WARNING, `enabled`, `parameters`, `when` opcional, `code/message` opcionales y `rule_id` estable. El código ausente se deriva de `type`. Publicar una regla nueva asigna `rule_id`; la lectura de configuraciones históricas nunca fabrica IDs ni altera sus fingerprints. La declaración se compila a una representación portable antes de evaluarse con el engine. No se admite scripting arbitrario ni Python eval/exec.

Tipo / código	Parámetros y semántica
required / REQUIRED	Campo presente, no null y no vacío. Whitespace no es vacío sin trim declarado.
not_null / NOT_NULL	Rechaza null.
unique / UNIQUE	Incumplen todos los registros duplicados; <code>null_policy</code> explícita.
compound_unique / COMPOUND_UNIQUE	Tupla de <code>columns</code> ; todos los miembros de una combinación repetida incumplen, sin concatenar valores con separadores ambiguos.
numeric / NUMERIC	Decimal finito con punto; conserva precisión.
positive / POSITIVE	Decimal estrictamente mayor que cero.
type / TYPE	<code>logical_type</code> STRING, INT64, DECIMAL, DATE, TIMESTAMP o BOOLEAN.
range / RANGE	<code>gt/gte</code> y <code>lt/lte</code> , límites Decimal inequívocos.
length / LENGTH	<code>min/max</code> enteros inclusivos en puntos de código Unicode observados, sin trim ni conteo por bytes.
allowed_values / ALLOWED_VALUES	valores con hasta 1000 escalares; pertenencia exacta.
regex / REGEX	Subconjunto portable Rust/RE2, flags <code>i/m/s</code> , máximo 500 caracteres.
date_rule / DATE_RULE	<code>not_future</code> , <code>min/max</code> ISO, <code>timezone</code> UTC y <code>null_policy</code> .
column_compare / COLUMN_COMPARE	Columna comparada contra <code>other_column</code> mediante <code>eq/ne/gt/gte/lt/lte</code> y <code>logical_type</code> STRING/DECIMAL/DATE/TIMESTAMP declarado.
reference / REFERENCE	Una o varias <code>columns</code> deben existir en <code>reference_columns</code> de una DatasetVersion explícita e inmutable.

`null_policy` admite ALLOW, FAIL o IGNORE según la regla. IGNORE excluye la fila de `evaluated_count`; no se cuenta como una evaluación aprobada. Los shorthand históricos `numeric/positive` conservan FAIL. El instante de referencia de fecha se fija al inicio del Run para que una misma ejecución no cambie de criterio entre registros.

Condiciones y referencias seguras

`when` acepta una condición tipada o un árbol `all/any`: hasta cuatro niveles, 64 nodos y diez condiciones por grupo. Los operadores son `eq/ne/gt/gte/lt/lte/is_null/not_null`. No hay código de usuario. Los literales se validan al publicar; una fecha o número mal formado no convierte silenciosamente una condición en falsa.

La condición filtra la población antes de evaluar la regla. En unicidad condicional se comparan únicamente las filas elegibles. Las excluidas por condición o IGNORE quedan en `skipped_count`. Ejemplo: `country eq CO -> required department`. El editor permite construir una condición simple con `columns` reales; la API admite árboles acotados. El editor conserva una condición compuesta existente sin reinterpretarla.

REFERENCE fija `dataset_version_id` y correspondencia de `columns` en el contrato. La API valida organización, existencia del snapshot y `columns`; el worker materializa exclusivamente el Parquet verificado mediante StorageProvider. La comparación de

tuplas conserva texto/null y no conecta desde el motor a una BD externa. El plan incluye el tamaño de las referencias; el manifest registra referencias y ArtifactLink registra RUN_REFERENCE. Un dataset de referencia vacío rechaza filas aplicables; null se gobierna por la política declarada.

Editor y resultados

Al elegir dataset, el editor carga su esquema. Columnas obligatorias, sin duplicados, numéricas y positivas usan multiselect con Todos; las positivas sólo permiten columnas numéricas. Las reglas avanzadas seleccionan columnas reales y muestran parámetros por tipo. Las referencias permiten elegir dataset, versión y columnas con su esquema persistido. El sistema detecta candidatos, pero el usuario decide las reglas. Actualizar esquema no obliga a escanear datasets completos. Responsable funciona como un catálogo deduplicado de owners de datasets y configuraciones del módulo; el usuario puede seleccionar uno o agregar una etiqueta nueva de hasta 120 caracteres. El contrato sigue persistiendo el mismo string owner: no es una cuenta, rol ni asignación de Excepciones.

Intake devuelve total_rows, valid_rows, error_rows, warning_rows, acceptance_rate y decisión APPROVED/APPROVED_WITH_WARNINGS/REJECTED según severidad y max_error_rate. Cada regla conserva rule_id cuando existe, code, columnas, severity, status, evaluated_count, failed_count, skipped_count, parámetros y condición. La evidencia identifica valor recibido y motivo. Una fila puede producir varios errores; error_rows cuenta registros afectados, no la suma de mensajes. WARNING conserva la fila aceptada y su advertencia. Una regla sin filas evaluadas no demuestra corrección técnica de una excepción.

El output reutilizable se guarda como Parquet INTAKE_ACCEPTED, con source_type=INTAKE_OUTPUT, canonical_artifact_id, parent_version_id y source_run_id. No tiene upload original ficticio. La UI muestra Artefacto derivado/Fuente de la versión y el linaje enlaza el input y el IntakeRun.

9. ReconOps y normalización declarada

ReconOps compara versiones inmutables de origen y destino. key_columns admite una o varias columnas. El control conserva key_normalization en su versión, config hash, manifest, plan y diagnostics.

El editor explica que las columnas clave identifican el mismo registro en ambos

lados y que, al seleccionar varias, forman una clave compuesta cuyo orden se

respeto. También aclara que la normalización se aplica antes de buscar

coincidencias y no modifica los datasets originales. Las opciones visibles son

“Conservar como están / Eliminar espacios externos”, “Conservar como están /

Convertir a MAYÚSCULAS / Convertir a minúsculas” y “No normalizar /

Normalización estándar (NFC) / Normalización de compatibilidad (NFKC)”. La ayuda

Unicode explica la diferencia entre representación visual e interna.

```
{"trim": false, "case": "NONE", "unicode_normalization": "NONE"}
```

case admite NONE/UPPER/LOWER y unicode_normalization NONE/NFC/NFKC. Los controles nuevos usan NONE por defecto. Los históricos sin el campo conservan el comportamiento legacy de trim mediante adaptación versionada; no se cambia silenciosamente el resultado de runs anteriores.

Una vista previa Antes / Después utiliza hasta diez registros reales de origen y

destino para mostrar la clave interna tras la normalización. En claves compuestas

representa todas las columnas como conjunto ordenado y permite contrastar ambos

lados. La muestra y el ejemplo dinámico se calculan en UI; no escriben datos ni

alteran trim booleano, case (NONE, UPPER, LOWER) ni

unicode_normalization (NONE, NFC, NFKC) persistidos.

Regla	Semántica
EXACT_COMPARE	Igualdad textual exacta tras la normalización declarada, con configuración independiente por par de columnas.
NUMERIC_TOLERANCE	Comparación Decimal con abs y percent opcional; denominador SOURCE/TARGET/MAX_ABS y política de denominador cero EXACT_ONLY. Umbral inclusivo.
DATE_TOLERANCE	Diferencia temporal contra hours o days, con zona UTC y equal_nulls.
AGGREGATE_COMPARE	1:N agregando destino o N:1 agregando origen, con una o varias operaciones SUM/COUNT sobre el mismo lado. comparison_rules consumen las columnas resultantes.

EXACT_MATCH se conserva como alias explícito legacy de NUMERIC_TOLERANCE. Una tolerancia numérica cero sigue comparando magnitudes: "01" y "1" pueden coincidir. Esto es distinto de EXACT_COMPARE. amount_column/tolerance históricos se adaptan sin modificar el snapshot.

Políticas y orden de ejecución

Cada comparación admite null_policy MATCH_NULLS, MISMATCH o INVALID; el adaptador conserva equal_nulls de controles históricos. Con MATCH_NULLS dos null coinciden, uno solo produce diferencia; MISMATCH considera cualquier null una diferencia; INVALID clasifica el registro como inválido. Un valor numérico/temporal mal formado conserva INVALID y nunca se equipara a un null válido.

El orden determinista es transforms de origen/destino, normalización de claves, agrupación explícita y comparaciones. Se configuran las transformaciones por columna y lado; no existen conversiones implícitas adicionales. Los parámetros se persisten en control, config hash, diagnostics, manifest y Excel.

Las agregaciones nuevas sólo conservan claves y outputs definidos. Una comparación no puede tomar arbitrariamente el primer valor no agregado de un grupo. SUM inválido se propaga a la comparación que consume ese output; COUNT puede evaluarse independientemente. Los controles históricos que usaban aggregation singular se leen con su comportamiento anterior; una nueva publicación debe satisfacer las validaciones actuales. No se admite N:M ni fuzzy matching.

Clasificaciones estables

MATCH, VALUE_MISMATCH, SOURCE_ONLY, TARGET_ONLY, DUPLICATE_SOURCE, DUPLICATE_TARGET e INVALID. Las filas duplicadas no se convierten en coincidencias arbitrarias. Las comparaciones conservan valores, regla, diferencia, tolerancia y líneas origen/destino; agregaciones conservan las líneas de sus integrantes.

metrics incluye source_rows/target_rows, matched, mismatched, faltantes, duplicados, invalid, total_rows, match_rate, counts por clasificación y evaluadas/fallidas/inválidas por comparación. La decisión es CONFORME o WITH_FINDINGS. Los hallazgos agrupan categorías distintas de MATCH; UI y Excel permiten revisar el detalle verificable de cada comparación y el linaje de ambos inputs.

La precisión monetaria se implementa con Decimal y contexto suficiente para sumas, diferencias y porcentajes. Las expresiones tienen pruebas de paridad Polars/DuckDB donde se declara soporte. No se infiere equivalencia de todo el pipeline entre motores a partir de estas pruebas.

10. Sentinel y métricas históricas

Sentinel ejecuta monitores sobre una DatasetVersion y produce checks explicables. Los controles legacy SCHEMA_REQUIRED, NULL_RATE, FRESHNESS y VOLUME_CHANGE permanecen compatibles. Una columna ausente se distingue de una columna presente con nulls.

En el editor, “Columnas requeridas” y “Columnas a revisar por nulos” son

selectores múltiples alimentados por el esquema de la DatasetVersion elegida.

Pueden conservar selecciones históricas mientras se publica una versión nueva;

backend sigue validando que los nombres y la organización sean correctos.

Control	Parámetros / cálculo
SCHEMA_REQUIRED	Lista de columnas obligatorias del monitor.
NULL_RATE	Columnas observadas y máximo permitido.
FRESHNESS	Edad respecto a fecha de versión y max_age_hours.
VOLUME_CHANGE	Cambio porcentual respecto a versión anterior.
DISTINCT_COUNT	Columna y min/max de valores distintos.
DISTINCT_RATE	Columna y límites en fracción 0..1.
UNIQUENESS_RATIO	Proporción de registros únicos, con límites 0..1.
SCHEMA_TYPE	Tipo esperado o comparación con el esquema de la versión anterior.
METRIC_THRESHOLD	Métrica/columna, operador y threshold o min/max.
HISTORICAL_BAND	window, min_history, iqr_multiplier y fallback explícito.

Las reglas por registro de Intake también pueden evaluarse como checks de Sentinel con conteos evaluados/fallidos/excluidos. El resultado indica code, name, status, actual, expected, severity, rule_id cuando existe y message. La severidad declarada llega a Findings y Excel. La salud es la fracción de checks aprobados; cero fallos da HEALTHY y cualquier fallo da ALERT, incluso cuando su severidad es WARNING.

Compatibilidad de series

SentinelMetricHistory conserva run_id, monitor_id, metric_key, dimensiones y hash, numeric_value, method, metric_definition_version y observed_at. Sólo se comparan ejecuciones SUCCESS con método/versión compatibles. El historial no mezcla perfiles legacy normalizados con observaciones nuevas exactas.

La banda histórica utiliza mediana e IQR con el método MEDIAN_IQR_LINEAR_V1. Cuando no hay historia suficiente, el resultado identifica FIXED_THRESHOLD_FALLBACK o PREVIOUS_COMPATIBLE_METRIC según la política. El expected muestra qué método se aplicó; no inventa una referencia estadística.

El monitor puede detectar schema drift sin que el worker falle técnicamente. El Run original conserva ALERT aunque una versión posterior vuelva a estar saludable. Las excepciones asociadas sólo se validan cuando una ejecución posterior del mismo snapshot de monitor termina HEALTHY.

Programación local e historia visible

El worker consulta monitor_schedules antes de consumir la cola existente. La programación referencia una Configuration inmutable. Una edición crea MonitorScheduleVersion con intervalo, activación, inicio y actor; no mueve programaciones a una nueva versión del monitor automáticamente. Se admiten intervalos de un minuto a 31 días. La UI recibe hora local y la convierte a UTC; la API exige zona explícita.

En cada despacho se fija la última DatasetVersion registrada. No se consulta ni actualiza automáticamente la fuente externa; el refresh de una conexión sigue siendo adquisición separada. MonitorOccurrence conserva configuración, revisión de horario, DatasetVersion, fecha prevista, despacho y Run. El Run aporta inicio real, finalización, estado, métricas y evidencia. La metadata

schedule se incluye en execution_plan y manifest.

COALESCE_LATEST agrupa intervalos vencidos tras una pausa; SKIP_WHILE_ACTIVE evita solapar runs del mismo monitor. NO_DATASET_VERSION documenta la ausencia de entrada. Cursor, ocurrencia, Run, Job y auditoría se confirman en una sola transacción con compare-and-swap y unicidad por fecha prevista. El actor es SYSTEM / trackvance:local-scheduler.

Mientras Docker o el worker están detenidos no hay ejecución. Un job largo puede retrasar el siguiente tick; la diferencia entre fecha prevista e inicio real queda visible. Las series agrupan muestras por métrica, dimensiones, método y versión, con un máximo de 2000 muestras recientes. Las alertas internas son Findings y aparecen en Sentinel y Centro de Control. NotificationDelivery prepara una interfaz futura; Email, Teams, Slack y Webhook no están integrados.

11. Excepciones con validación técnica

Una excepción nace de un Finding y conserva finding_id, run_id de origen y configuration_id del snapshot que lo produjo. El Run de origen nunca cambia su decisión porque un caso se cierre o los datos se corrijan.



Estado	Función
OPEN / Abierta	Hallazgo convertido en caso, pendiente de gestión.
ASSIGNED / Asignada	Caso asignado a un usuario activo y autorizado de la organización.
INVESTIGATING / En gestión	Responsable investiga causa y prepara corrección.
PENDING_VALIDATION	Espera evidencia técnica posterior.
RESOLVED / Resuelta	Evidencia válida, causa y resolución documentadas.
DISCARDED / Descartada	Cierre administrativo con motivo obligatorio.
ACCEPTED / Aceptada	Riesgo o situación aceptada con motivo obligatorio.
NOT_APPLICABLE / No aplica	Cierre administrativo justificado.
REOPENED / Reabierta	Caso cerrado que vuelve a gestión con comentario y nueva fecha de referencia.

Criterios de elegibilidad

Se requiere un Run posterior SUCCESS, de la misma organización y el mismo configuration_id. Publicar otra versión de configuración crea otro snapshot y no valida automáticamente la excepción anterior. Se selecciona la candidata elegible más reciente; no se acepta una validación positiva obsoleta cuando existe una ejecución posterior que vuelve a fallar.

- Intake: la regla con rule_id que originó el hallazgo debe estar presente, evaluar al menos una fila y tener cero incumplimientos. En un caso histórico abierto sin ID se identifica la regla mediante su código/columna y fingerprint compatible, pero también se exigen métricas suficientes: evaluated_count mayor que cero y failed_count igual a cero. La mera ausencia de otro Finding no

demuestra que la regla se haya evaluado.

- ReconOps: el control debe quedar conforme o desaparecer la clasificación asociada al hallazgo.
- Sentinel: el monitor debe volver a HEALTHY.

La UI deshabilita Resolver mientras no se cumplen los criterios y muestra el motivo. Una validación correcta se presenta como Validada técnicamente y enlaza el Run confirmatorio. Resolver sólo se acepta desde PENDING_VALIDATION y exige causa raíz y resolución. La API reevalúa antes de guardar.

El worker actualiza evidencia de casos PENDING_VALIDATION al terminar un Run. Conserva validation_run_id, validated_at, validation_evidence y evento TECHNICAL_VALIDATION. auto_resolve_enabled es una política por caso deshabilitada por defecto; habilitarla requiere permiso de cierre. Cuando está activa y la misma comprobación técnica es válida, el worker puede resolver el caso con actor SYSTEM, evento EXCEPTION_AUTO_RESOLVED, política CASE_OPT_IN y Run confirmatorio. No inventa una causa raíz humana y no duplica cierres en reintentos.

Gestión operativa

Cada caso admite assigned_user_id, prioridad, SLA en horas, due_at, comentarios y adjuntos. La prioridad es independiente de la severidad histórica. El SLA se calcula desde creación o reapertura, con UTC; una fecha objetivo explícita prevalece. No hay calendario laboral implícito. Los filtros backend cubren estado, módulo, severidad, prioridad, responsable, vencimiento y texto.

Reabrir exige comentario; conserva el cierre anterior en timeline y reinicia el plazo. Una ejecución creada antes de la reapertura no prueba la corrección actual. Se preservan las transiciones históricas OPEN -> INVESTIGATING y reapertura hacia OPEN para compatibilidad.

Los adjuntos permitidos se limitan a 10 MiB, se publican inmutables mediante StorageProvider y registran Artifact EXCEPTION_ATTACHMENT, hash y relación EXCEPTION_EVIDENCE. No se ejecutan ni se usan como reglas. La descarga exige organización/permisos, verifica integridad, fuerza attachment/nosniff y genera auditoría. Nombre y descripción se sanitizan; el filename nunca define una ruta física.

Las mutaciones usan version para concurrencia optimista. Timeline conserva actor estable, fecha, estado anterior/nuevo, comentario y referencia de validación. Los cierres administrativos no equivalen a RESOLVED ni fabrican evidencia. WAITING_EXTERNAL/FALSE_POSITIVE y resoluciones históricas permanecen legibles; los registros anteriores sin prueba se identifican como históricos, sin inventar un Run confirmatorio.

Si el Run candidato no contiene métricas suficientes para identificar y probar la regla histórica, el nuevo cierre queda bloqueado con motivo de evidencia insuficiente. Se requiere ejecutar nuevamente el mismo control y obtener evidencia verificable. Esto no modifica casos ya RESOLVED ni sus timelines históricos; endurece únicamente las nuevas decisiones de resolución.

12. Centro de Control y navegación

El Centro de Control es un cockpit operativo calculado por backend. El usuario puede identificar qué falla, qué requiere atención y abrir la acción correspondiente. Las cifras no son constantes de presentación.

Elemento	Comportamiento actual
Filtros globales	Período 7d/30d/90d/all, dataset, módulo, estado operativo y criticidad.
Indicadores superiores	Salud general, controles fallidos, excepciones abiertas y datasets afectados. Variación contra período anterior cuando existe una comparación válida.
Requiere tu atención	Excepciones, hallazgos y fallos priorizados; muestra dataset, módulo, problema, fecha y acción directa.
Salud de los datos	Evolución temporal y desglose Intake/Recon/Sentinel.
Datasets afectados	Salud, hallazgos, última ejecución y tendencia.
Resumen por módulo	Ejecuciones/controles/monitores con fallos y alertas.
Ejecuciones recientes	Dataset, registros, hallazgos y duración cuando están disponibles; estado técnico separado de decisión.
Accesos rápidos	Carga de dataset y ejecución de operaciones.

health_score se pondera por unidades evaluadas según la agregación del backend. Las variaciones devuelven previous/delta o null cuando no hay base válida. Los filtros respetan organización y los enlaces navegan al recurso correspondiente. No se presenta ausencia de historia como mejora o deterioro.

Rutas SPA

/; /datasets; /datasets/:id; /connections; /intake/*; /recon/*; /sentinel/*; /runs; /runs/:id; /exceptions; /rules; /audit; /settings/*. La administración de usuarios está integrada en Configuración. El menú conserva los módulos y el diseño navy/teal. Estados de carga, vacío y error tienen tratamiento específico; se conserva request_id en errores para diagnóstico.

Cerrar sesión confirma /auth/logout, limpia token CSRF, caché de consultas y

estado de sesión, y navega con reemplazo a /. El usuario vuelve a la pantalla

inicial de Trackvance —incluido “Entrar al entorno demo” cuando esté habilitado—

sin mantener una pantalla autenticada en el historial inmediato.

Los detalles de dataset separan archivo original, fuente derivada, esquema/perfil y linaje. Los detalles de run separan Completada de Rechazado/Con hallazgos/Alerta. Los labels de negocio acompañan reason codes técnicos en resultados y evidencia. La numeración se muestra como Línea del archivo cuando representa línea física o Registro de la versión cuando corresponde.

13. StorageProvider, artefactos y linaje

StorageProvider es el puerto de almacenamiento interno. temporary_path asigna staging local temporal; put_file publica bytes y metadata inmutables; materialize/materialize_reference obtiene un archivo verificable para el motor local; open_read/exists completan el acceso. Un adaptador remoto deberá administrar su cache materializado y su ciclo de limpieza.

FileArtifactStore confina las rutas al root configurado, verifica tamaño/SHA-256 y publica sin reemplazar bytes históricos. El nombre recibido nunca se usa como path arbitrario. Los servicios nuevos no construyen el layout del volumen; el adaptador conserva registro directo/promote para compatibilidad y backfill.

Kind	Uso
ORIGINAL_UPLOAD	Archivo realmente recibido del usuario.
CANONICAL_PARQUET	Representación canónica de una versión cargada.
INTAKE_ACCEPTED	Parquet de filas aceptadas; base reutilizable de versión derivada.
INTAKE_ERRORS	Detalle de incumplimientos Intake.
RECON_RESULTS	Resultados detallados de conciliación.
SENTINEL_PROFILE	Checks/resultados del monitor.
RUN_MANIFEST	Evidencia JSON de ejecución.
EXPORT_XLSX	Reporte estructurado generado bajo demanda.
EXCEPTION_ATTACHMENT	Evidencia documental adjunta a un caso, inmutable y con hash.
GENERATED_DEMO / legacy	Datos ficticios o artefactos históricos identificados explícitamente.

Artifact guarda id, organization_id, kind, name, path interno, sha256, size_bytes, media_type y fecha. ArtifactLink registra relaciones dirigidas DERIVED_FROM, RUN_INPUT, RUN_OUTPUT, INTAKE_ACCEPTED_FROM, RUN_REFERENCE, EXCEPTION_EVIDENCE, SOURCE_SNAPSHOT, REFRESH_OF y EXPORT_OF entre versiones, runs, fuentes y artefactos.

Antes de procesar o descargar, se comprueba la identidad registrada y su integridad.

ARTIFACT_HASH_MISMATCH/ARTIFACT_INTEGRITY_ERROR impide usar bytes corruptos; no recalcula silenciosamente el hash histórico. El backfill aditivo registra archivos legacy verificables, cuenta ausentes/corruptos y conserva historia.

Una publicación interrumpida puede dejar bytes huérfanos no referenciados después de un rollback. Esos bytes no reemplazan artefactos válidos. Retención, recolección de huérfanos y políticas de object storage son evolución pendiente y deben implementarse con referencias transaccionales y auditoría.

14. Manifest schema 2 y auditoría

Cada Run completado publica un manifest inmutable con `schema_version=2`. `read_manifest/adapt_manifest` centraliza la lectura de v1 histórico; la adaptación se realiza en memoria, sin sobrescribir archivos anteriores.

```
{
  "schema_version": 2,
  "run_id": "<id>",
  "module": "recon",
  "initiated_by": {
    "type": "USER", "id": "<id estable>",
    "display_name": "Equipo Trackvance"
  },
  "result_artifacts": [{
    "artifact_id": "<id>", "kind": "RECON_RESULTS",
    "name": "results.parquet", "sha256": "<hash>",
    "size_bytes": 1234
  }]
}
```

El contrato completo incluye `started_at/finished_at`, `identidad/legacy`, versión de Trackvance, plan processing con `engine/version` y `schedule` cuando corresponde, `inputs` con `DatasetVersion`/`SHA`/`schema hash`/`origen/ingestion_metadata`, configuración efectiva/`id/version/config_hash/stored_config_hash`, métricas, `output_version_id` y `result_artifacts`. `references` añade identidad y hashes de `DatasetVersions` usadas para integridad referencial; es una extensión aditiva de schema 2. Los snapshots anteriores no se reescriben.

La versión del producto y la del motor se distinguen: `engine_version` de nivel superior identifica Trackvance en el manifest actual; `processing.engine_version` identifica la versión real de Polars. La UI y exports muestran ambas con su contexto.

Identidad y eventos

`AuditEvent` conserva `actor_type`, `actor_id` estable, `actor` visible, `actor_legacy`, `event_type`, `subject_type/id`, `request_id`, `run_id`, `metadata` sanitizada y `timestamp`. Actor puede representar `USER`, `WORKER` o `SYSTEM`. Los nombres visibles no sustituyen la identidad persistente.

`DATASET_UPLOADED`, `DATASET_DERIVED`, `CONFIGURATION_PUBLISHED`, `RUN_QUEUED`, `RUN_COMPLETED`, `EXCEPTION_CREATED`, `EXCEPTION_UPDATED` y `EXCEPTION_VALIDATION_CHECKED` documentan el ciclo. `EXPORT_DOWNLOADED`, `EVIDENCE_DOWNLOADED` y `ARTIFACT_DOWNLOADED` registran el acceso relevante a evidencia. La UI enlaza recursos desde los eventos.

La administración añade `USER_CREATED`, `USER_UPDATED` y `USER_PASSWORD_RESET`. La gestión operativa audita comentarios, adjuntos y resolución automática; la programación conserva revisiones y eventos de despacho. Las filas de negocio recibidas, credenciales, hashes de contraseña y sesiones nunca forman parte del payload público de estos eventos.

Se excluyen claves de passwords, tokens y secretos de metadata/evidencia. Los casos legacy sin identidad demostrable se marcan como legacy; no se atribuyen a un UUID de usuario inventado. Las auditorías de exportación agregan evidencia sin alterar el manifest original del Run.

15. Reportes Excel de negocio

IMPLEMENTADO. La UI ofrece Exportar Excel y genera .xlsx mediante openpyxl. CSV permanece únicamente como endpoint deprecated para consumidores históricos. El Excel es un artefacto derivado; Parquet sigue siendo canónico.

Módulo	Hojas y contenido
Intake	Resumen: contrato/version, dataset/version, run, fechas, estado/decisión, filas/tasas/umbral/motor y reglas con evaluadas/fallidas/excluidas/severidad. Errores: línea, regla, columnas, valores recibidos, severidad, motivo y clasificación. Reglas: configuración efectiva. Trazabilidad: inputs, referencias, IDs/hashes/actor/plan/artefactos.
ReconOps	Resumen: control, ambos inputs, claves/comparaciones/tolerancias/nulls/transforms/agregaciones, siete conteos y match rate. Resultados: clave, clasificación, valores, diferencia, tolerancia, líneas, mensaje y comparaciones. Hallazgos: no MATCH. Trazabilidad: ambos inputs y evidencia.
Sentinel	Resumen: monitor, versión, filas, checks/fallos, salud y decisión. Controles: código/estado/observado/esperado/detalle, severidad y conteos evaluados/fallidos/excluidos. Hallazgos: sólo fallidos. Trazabilidad: input, referencias, configuración, motor y artefactos.

El diseño usa encabezados navy, teal para acentos, rojo para incumplimientos y amber para warning. Tablas con autofiltro, paneles inmovilizados, anchos legibles, ajuste de texto y formatos de fecha, porcentaje y decimal. Las columnas técnicas se concentran en Trazabilidad y los reason codes siguen disponibles.

Tipos y seguridad

Identificadores se escriben como texto. Decimales de más de 15 cifras significativas también se conservan como texto para evitar pérdida de precisión de Excel. Los valores de negocio que comienzan con =, +, -, @, tabulación o espacios nunca se convierten en fórmula ejecutable ni link externo. Las reglas de formato condicional son constantes internas.

No se trunca evidencia silenciosamente: celdas mayores que 32767 caracteres o tablas que exceden límites de Excel producen EXPORT_LIMIT_EXCEEDED. Controles XML inválidos se escapan de forma visible. Passwords/tokens/secrets no se incluyen.

GET /runs/{id}/export.xlsx exige sesión, exports:download, organización, SUCCESS e integridad de manifest/resultados. El MIME es application/vnd.openxmlformats-officedocument.spreadsheetml.sheet; Content-Disposition usa trackvance_<module>_<run>.xlsx sanitizado y X-Artifact-ID identifica el export. Se registra EXPORT_XLSX/EXPORT_OF y auditoría.

16. Ejecución, planificación y recuperación

POST de ejecución valida configuración/versions, fija actor e inputs inmutables, calcula preflight y crea Run más Job en la misma sesión. Idempotency-Key evita crear runs duplicados para el mismo endpoint/organización/key/payload; cambiar el payload con la misma key produce IDEMPOTENCY_CONFLICT.

Estado técnico	Significado
QUEUED	Trabajo persistido esperando worker.
RUNNING	Worker posee lease y procesa la ejecución.
SUCCESS	Procesamiento terminado y evidencia publicada; decisión de negocio separada.
FAILED	Error técnico durante ejecución.
FAILED_PRECONDITION	Preflight no permite ejecutar; no se simula resultado.
CANCELLED	Cancelación atendida por el worker.

DatabaseJobQueue publica Jobs con run_id único. El worker reclama trabajos elegibles con actualización condicional, identifica propietario y lease_until, registra intentos y recupera leases vencidos. Heartbeat informa actividad local y salud. Antes de publicar

resultados se revalida lease; los intentos no sobrescriben evidencia histórica.

ExecutionPlanner

Estima memoria de trabajo desde bytes/filas/columnas y un factor mayor para Recon. Comprueba disco temporal libre. Los defaults son 512 MiB de presupuesto blando, 16 MiB de reserva mínima de disco y 300 segundos en resource_budget. Estos valores son configurables por entorno.

El pipeline real es Polars/Python. Si la estimación requiere PySpark, el plan rechaza con ENGINE_UNAVAILABLE; disco insuficiente produce RESOURCE_DISK_INSUFFICIENT. No hay fallback silencioso ni adapter Spark instalado. DuckDB se usa en metadata y paridad de expresiones, no como pipeline completo seleccionable.

La presencia de timeout_seconds en el plan no equivale a un límite duro por proceso. La interrupción bajo carga, kill/restart de procesos y el presupuesto real de memoria requieren certificación de estrés adicional. La cancelación es cooperativa; Redis/Celery, prioridades/lanes y workers distribuidos son futuros.

17. Modelo persistente y migraciones

PostgreSQL mantiene 21 tablas de aplicación, además del control de revisión de Alembic. El esquema real es más compacto que el ERD objetivo inicial: organización se expresa mediante organization_id lógico y roles mediante users.role más política central. No existen tablas dedicadas organizations/roles/permissions; la administración de los cinco roles base está implementada sobre el modelo actual.

Tabla	Identidad / relación principal
users	Usuario, organization_id, role, password_hash, active, version y fechas de actualización/cambio de contraseña.
sessions	Token hash, usuario, CSRF y expiración.
datasets	Nombre único por organización, área, owner, criticidad y estado.
dataset_versions	Versión única por dataset, schema/profile, artifacts y lineage.
configurations	Snapshot por módulo; previous_version_id y datasets.
runs	Snapshot de inputs/config, actor, plan, métricas, decisión y evidencia.
jobs	Run único, estado, intentos y lease.
findings	Run, código, fingerprint único por Run y detalles.
exceptions	Finding único, configuración, origen, validación, asignación, prioridad, SLA, reapertura, política automática y timeline/version.
exception_attachments	Caso, artifact inmutable, autor y descripción.
audit_events	Actor estable, sujeto, request/run y metadata sanitizada.
idempotency_keys	Organización/ruta/key, hash request y Run.
artifacts	Identidad inmutable, kind, locator, hash/tamaño/MIME.
artifact_links	Relación dirigida única entre entidades.
metric_history	Métrica/dimensión/run, método/version y valor.
external_connections	Identidad, revisión vigente, estado y última prueba; ámbito por organización.
external_connection_versions	Configuración inmutable, referencia de secreto y config_hash.
dataset_source_bindings	Dataset, conexión, schema, tabla/vista y overrides.
monitor_schedules	Monitor único, revisión vigente, habilitación, cursor y fecha de actualización.
monitor_schedule_versions	Revisión inmutable del intervalo, inicio, activación y actor de una programación.
monitor_occurrences	Programación/revisión, monitor, versión evaluada, fecha prevista/real, estado, motivo y Run.

Cadena de trazabilidad

Conexión/revisión -> Dataset -> DatasetVersion -> Configuration -> Run -> Finding -> Exception. La excepción añade Validation Run de la misma Configuration y artifacts adjuntos. La programación vincula su revisión y fecha prevista al Run; las reglas referenciales añaden snapshots de consulta. ArtifactLink conecta originales, canónicos, outputs, manifests y exports. Las claves de organización y comprobaciones del servicio acotan todos los accesos.

Migración	Cambio
0001_initial	Esquema original.
0002_evidence_v2	Identidad, artefactos, linaje, evidencia y métricas versionadas.
0003_dataset_ingestion_metadata	Formato/lector/opciones/esquema nativo por versión.
0004_exception_validation	Configuración de origen, validación técnica y cierre administrativo.
0005_external_connections	Conexiones externas, configuraciones versionadas y bindings de datasets.
0006_local_identity_exceptions	Versionado de usuarios, fechas, campos operativos de excepciones y exception_attachments.
0007_monitor_scheduling	Programaciones, revisiones inmutables y ocurrencias Sentinel; unicidad e índices de despacho.

La revisión vigente es 0007_monitor_scheduling. Todas las evoluciones son migraciones aditivas nuevas; no se modifican migraciones aplicadas. API startup aplica Alembic y backfill idempotente. SQLite legacy sólo se adopta cuando coincide con un schema reconocido; no se fuerza sobre estructuras desconocidas. Downgrade/upgrade se prueban en bases temporales, nunca sobre datos operativos.

18. API y errores

La base es /api/v1. OpenAPI generado desde FastAPI y backend/API_CONTRACT.md son las referencias de campos exactos. El inventario siguiente se genera desde backend/openapi.json y conserva rutas reales, incluidos alias y compatibilidad deprecated.

Método	Ruta	Operación
GET	/health	Health
GET	/health/ready	Ready
GET	/api/v1/health	Health
GET	/api/v1/health/ready	Ready
POST	/api/v1/auth/demo	Demo Login
POST	/api/v1/auth/login	Login
GET	/api/v1/me	Me
POST	/api/v1/auth/logout	Logout
GET	/api/v1/datasets	Datasets
POST	/api/v1/datasets	New Dataset
POST	/api/v1/datasets/uploads/inspect	Inspect Dataset Upload
GET	/api/v1/datasets/{dataset_id}	Dataset Detail
GET	/api/v1/datasets/{dataset_id}/schema	Dataset Schema
POST	/api/v1/datasets/{dataset_id}/versions/upload	Upload Version
GET	/api/v1/dataset-versions/{version_id}/profile	Profile
GET	/api/v1/monitors	Configurations
POST	/api/v1/monitors	Monitor

Método	Ruta	Operación
GET	/api/v1/recon/controls	Configurations
POST	/api/v1/recon/controls	Recon Control
GET	/api/v1/intake/contracts	Configurations
POST	/api/v1/intake/contracts	Intake Contract
POST	/api/v1/intake/runs	Intake Run
POST	/api/v1/recon/runs	Recon Run
POST	/api/v1/monitors/{monitor_id}/runs	Monitor Run
GET	/api/v1/runs	Runs
GET	/api/v1/runs/{run_id}	Run Detail
POST	/api/v1/runs/{run_id}/cancel	Cancel Run
GET	/api/v1/recon/runs/{run_id}/results	Results
GET	/api/v1/intake/runs/{run_id}/errors	Results
GET	/api/v1/runs/{run_id}/results	Results
GET	/api/v1/runs/{run_id}/evidence	Evidence
GET	/api/v1/artifacts/{artifact_id}/download	Artifact Download
GET	/api/v1/runs/{run_id}/export.xlsx	Export Excel
GET	/api/v1/runs/{run_id}/export.csv	Export Csv (legacy)
GET	/api/v1/monitors/{monitor_id}/metrics	Monitor Metrics
GET	/api/v1/findings	Findings
POST	/api/v1/findings/{finding_id}/exceptions	Finding Exception
GET	/api/v1/audit-events	Audit Events
GET	/api/v1/rules	Rules
GET	/api/v1/system/engines	Engines
GET	/api/v1/dashboard	Dashboard
POST	/api/v1/monitors/{configuration_id}/versions	Publish Configuration Version
POST	/api/v1/recon/controls/{configuration_id}/versions	Publish Configuration Version
POST	/api/v1/intake/contracts/{configuration_id}/versions	Publish Configuration Version
GET	/api/v1/runs/{run_id}/execution-plan	Run Execution Plan
GET	/api/v1/runs/{run_id}/diagnostics	Run Diagnostics
POST	/api/v1/execution-plans/preview	Preview Execution
GET	/api/v1/connections	List Connections
POST	/api/v1/connections	Create Connection
POST	/api/v1/connections/test	Test Draft
GET	/api/v1/connections/{connection_id}	Connection Detail
PATCH	/api/v1/connections/{connection_id}	Update Connection
DELETE	/api/v1/connections/{connection_id}	Delete Connection
POST	/api/v1/connections/{connection_id}/test	Test Connection

Método	Ruta	Operación
GET	/api/v1/connections/{connection_id}/schemas	Schemas
GET	/api/v1/connections/{connection_id}/objects	Objects
GET	/api/v1/connections/{connection_id}/preview	Preview
POST	/api/v1/connections/{connection_id}/datasets	Register Source Dataset
POST	/api/v1/datasets/{dataset_id}/refresh-source	Refresh Source
GET	/api/v1/users	Users
POST	/api/v1/users	Create User
GET	/api/v1/users/roles	Roles
GET	/api/v1/users/{user_id}	User Detail
PATCH	/api/v1/users/{user_id}	Edit User
POST	/api/v1/users/{user_id}/reset-password	Reset Password
GET	/api/v1/exceptions	Exceptions
GET	/api/v1/exceptions/assignees	Assignees
GET	/api/v1/exceptions/{case_id}	Detail
PATCH	/api/v1/exceptions/{case_id}	Update Case
POST	/api/v1/exceptions/{case_id}/validate	Validate
POST	/api/v1/exceptions/{case_id}/comments	Comment
POST	/api/v1/exceptions/{case_id}/attachments	Upload Attachment
GET	/api/v1/exceptions/{case_id}/attachments/{attachment_id}/download	Attachment Download
GET	/api/v1/monitors/{monitor_id}/schedule	Get Schedule
POST	/api/v1/monitors/{monitor_id}/schedule	Configure Schedule
GET	/api/v1/monitors/{monitor_id}/occurrences	Occurrences
GET	/api/v1/monitors/{monitor_id}/series	Metric Series
GET	/api/v1/monitors/{monitor_id}/alerts	Monitor Alerts

19. Contratos HTTP y permisos

Las listas comunes devuelven {items,total}; IDs son strings opacos y fechas ISO UTC. El cockpit devuelve un DTO agregado. Los downloads usan el MIME del artefacto verificado y filename sanitizado.

Autenticación utiliza cookie HttpOnly trackvance_session. Mutaciones autenticadas requieren X-CSRF-Token y validación de origen. Sesiones duran 12 horas en el prototipo. Passwords se verifican mediante Argon2. El acceso demo es explícito, depende de DEMO_ACCESS_ENABLED y no representa SSO de producción. DEMO_SEED_ENABLED controla por separado la creación de datos sintéticos.

Rol	Alcance local
Administrator	Lectura, autoría, ejecución, exports, auditoría, sistema, cierre de excepciones y administración/uso de conexiones.
Data Owner / Lead	Lectura/autoría/ejecución, exports, auditoría, cierre y administración/uso de conexiones.
Data Analyst	Lectura/autoría/ejecución, exports, auditoría y uso de conexiones; sin administración de conexiones ni cierre de excepciones.
Operations	Lectura/exports y gestión de excepciones según permiso; solo consulta metadata de conexiones.
Auditor	Lectura/exports/auditoría/usuarios/sistema y metadata de conexiones; sin mutaciones operativas.

permissions.py es la política central; roles desconocidos no reciben permisos. Se distinguen datasets:read/write, configurations:write, runs:read/execute, exceptions:read/write/close, connections:read/use/manage, exports:download, artifacts:download, audit:read, users:read/write y system:read. connections:read permite consultar metadata; use permite probar una conexión guardada, explorar y adquirir snapshots; manage permite crear, editar, deshabilitar, eliminar y probar borradores. Los cierres técnicos y administrativos requieren exceptions:close además del permiso de gestión.

Administración local implementada

Administrator puede listar, crear, editar, activar/desactivar usuarios, asignar roles base y restablecer contraseña. Auditor consulta cuentas y permisos efectivos; los demás accesos dependen de users:read/write. Las bajas son desactivaciones para conservar referencias históricas. Data Owner es un alias compatible de Data Owner / Lead; no se admiten roles arbitrarios.

La contraseña explícita usa SecretStr, de 12 a 1024 caracteres, no se recorta y sólo persiste como hash Argon2. El reset define una nueva contraseña y revoca todas las sesiones; cambiar correo, rol o actividad también las revoca. Las respuestas nunca incluyen hash, token, sesión ni contraseña. El administrador entrega la contraseña por un canal seguro fuera de Trackvance.

Las mutaciones requieren version y compare-and-swap. La degradación o desactivación de administradores protege al último administrador activo de la organización mediante bloqueo transaccional en PostgreSQL. Los conflictos de correo no revelan organizaciones ajenas. El middleware verifica rol y actividad actuales en cada solicitud. OIDC/SSO y directorio multi-organización administrable continúan como objetivos posteriores.

Errores operativos

El envelope es {error:{code,message,details,request_id}}. Sesión inválida devuelve 401; permiso/CSRF 403; recurso no accesible 404; conflicto/integridad 409; validación 422; readiness fallido 503. La UI conserva el mensaje legible y la referencia de diagnóstico.

VALIDATION_RUN_REQUIRED, VALIDATION_RUN_OUTDATED, TECHNICAL_VALIDATION_REQUIRED y ADMINISTRATIVE_REASON_REQUIRED protegen las excepciones. VERSION_CONFLICT evita sobrescritura por formularios obsoletos. UNSUPPORTED_FORMAT, INVALID_DATA y UPLOAD_TOO_LARGE explican rechazos de carga. DATASET_NAME_EXISTS distingue el nombre duplicado de un conflicto genérico.

Hardening objetivo: rate limiting, federación OIDC, sensibilidad/masking, política de retención, administración productiva de sesiones y pruebas de penetración. No deben asumirse por existir sesión/RBAC y administración local.

20. Configuración, operación y respaldo

La configuración es por entorno y defaults locales. `.env.example` es una plantilla sin secretos operativos. `.env`, `storage`, datos de usuario, caches, logs, resultados temporales y backups se excluyen de Git y del contexto Docker según `.gitignore/.dockerignore`.

Variable	Función / default
DATABASE_URL	PostgreSQL en Compose; SQLite local en ejecución directa.
TRACKVANCE_STORAGE_DIR / ROOT	Raíz interna; <code>/var/lib/trackvance</code> en Compose.
TRACKVANCE_WEB_ORIGIN	Origen esperado; debe coincidir con <code>WEB_PORT</code> .
COMPOSE_PROJECT_NAME / WEB_PORT	Instalación y puerto; no confundir volúmenes entre proyectos.
POSTGRES_DB/USER/PASSWORD	Acceso local a metadata; password sólo en entorno.
TRACKVANCE_SECRETS_DIR	Volumen de credenciales cifradas externas.
TRACKVANCE_SECRET_KEY_FILE	Clave maestra local en volumen independiente.
DEMO_ACCESS_ENABLED	Habilita únicamente el login demo explícito; garantiza la identidad y organización mínimas, no datos sintéticos.
DEMO_SEED_ENABLED	Habilita únicamente el seed idempotente de datasets, configuraciones, ejecuciones, hallazgos y excepciones demo.
MAX_UPLOAD_BYTES / TRACKVANCE_MAX_ROWS	10 MiB y 100.000 filas por defecto.
TRACKVANCE_WORKER_MEMORY_SOFT_BYTES	Presupuesto blando del planner.
TRACKVANCE_TEMP_MIN_FREE_BYTES	Reserva mínima de disco temporal.
TRACKVANCE_RUN_TIMEOUT_SECONDS	Valor del plan; no timeout duro certificado.

Para conservar el cierre seguro de instalaciones anteriores, si `DEMO_ACCESS_ENABLED` está ausente hereda el valor de `DEMO_SEED_ENABLED`. Al definir ambas variables explícitamente sus comportamientos son independientes.

`TRACKVANCE_ENV` aparece como etiqueta en la plantilla; no selecciona por sí sola una política de seguridad productiva. No hay Settings Pydantic ni feature flags persistidos actualmente.

Readiness comprueba SQL, Alembic head y escritura temporal. `doctor.py` comprueba HTTP, servicios, migraciones y heartbeat, sin imprimir DSN ni secretos. `verify_storage.py` snapshot calcula hashes de registros de negocio, valida todos los artifacts y verifica referencias/credenciales cuando corresponde; `compare` exige igualdad antes/después de un reinicio en reposo. Entre capturas no deben ejecutarse login/exports/tests que agregan auditoría legítima.

El respaldo SQLite usa una copia consistente, integra WAL, verifica hashes y restaura en destino nuevo con rutas reubicadas. Incluye credenciales cifradas y clave maestra; una referencia de conexión sin su secreto o clave invalida el respaldo. La restauración conserva estos archivos en `credentials/` y `keys/` del destino con acceso restringido y mantiene compatibilidad con backups históricos sin conexiones.

Respaldo Docker consistente

`scripts/docker_state.py` backup requiere proyecto explícito Trackvance, etiquetas Compose verificables y los cuatro volúmenes esperados. Detiene temporalmente web y worker, captura el estado consistente, detiene API y produce `pg_dump` custom de PostgreSQL. Copia `trackvance_data`, `connection_credentials` y `connection_keys` con su inventario; no copia en caliente el data directory PostgreSQL. Finalmente restaura sólo los contenedores que estaban activos al comenzar.

backup-manifest.json registra schema_version, consistencia quiesced, fecha, proyecto, Alembic, versión PostgreSQL, revisión Git, imágenes y hashes/tamaños de cada componente. state.json conserva la huella verificable de metadata, artifacts y referencias. verify comprueba manifest, componentes exactos, hashes, rutas y archivos; rechaza enlaces y archivos no declarados. El conjunto contiene la clave necesaria para descifrar las credenciales y debe guardarse con acceso restringido. .env se conserva separadamente y no se imprime ni se incluye automáticamente en el backup.

La transferencia de archivos usa streaming: el helper escribe el tar por stdout hacia un archivo abierto por el proceso del host; la restauración envía ese archivo por stdin. No carga el archivo completo en RAM ni necesita un bind mount del directorio del host o elevar el helper a root. En POSIX se crean directorios de backup 0700 y archivos 0600; los contenidos restaurados conservan los modos verificados. El helper sólo monta el volumen necesario y permanece sin red.

```
python scripts/docker_state.py backup --project trackvance-local --destination backups/local
python scripts/docker_state.py verify --source backups/local
```

Restauración en proyecto nuevo

restore exige nombre distinto del origen y ningún recurso preexistente. Reconstruye volúmenes nuevos, restaura el dump en una transacción, repone artifacts/credenciales/clave, inicia API y valida Alembic y la igualdad de la huella. Sólo inicia el resto del sistema con --start; sin esa opción deja el destino detenido tras verificarlo. --smoke requiere --start y está reservado para un ensayo aislado con identidad demo disponible. La salida es un recibo de restauración con hash del manifest y estado de verificación, sin secretos.

```
python scripts/docker_state.py restore --source backups/local `
--target-project trackvance-restored --web-port 3200 --start
```

La instalación destino debe disponer del código/imágenes y configuración de entorno compatibles. Una restauración fallida detiene el proyecto nuevo para diagnóstico; no borra el origen ni lo reemplaza. La prueba E2E destruye sólo su entorno temporal, restaura y comprueba hashes y funcionalidad, incluidos secretos y reconexión a motores de prueba. La evidencia ejecutada se registra en aceptación.

El drill ampliado trackvance-recovery-src-stream-e20a -> trackvance-recovery-dst-stream-e20a terminó PASS utilizando la transferencia por streaming: eliminó el proyecto fuente antes de restaurar y verificó siete artifacts, un secreto, 124 relaciones y Alembic 0007_monitor_scheduling. La credencial PostgreSQL restaurada permitió conectar, refrescar a DatasetVersion v2 y ejecutar el mismo contrato: el nuevo Run fue APPROVED y el original permaneció REJECTED. Se conservaron hashes, linaje e historia y pasaron doctor, smoke API y búsqueda de secretos en logs. El resultado saneado se versiona en docs/development/evidence/0.4.0/recovery.json.

La recuperación incluyó una excepción con responsable/SLA y un adjunto, además de una programación Sentinel, dos revisiones, una ocurrencia y 31 muestras de métricas. El caso conservó su timeline y quedó PENDING_VALIDATION con validación técnica VALIDATED tras la nueva ejecución; auto_resolve_enabled permaneció false. La programación siguió pausada y su ocurrencia, métricas y alertas históricas se conservaron. El drill verificó HTML HTTP 200; Playwright no se ejecutó dentro de este ensayo y su certificación es independiente. Su resultado schema 3 y los ensayos previos quedan como evidencia separada.

Reset deliberado

El reset destruye metadata, datasets, runs, artifacts y secretos del proyecto seleccionado. El script Windows soportado detecta COMPOSE_PROJECT_NAME y delega en plan-reset/reset de docker_state.py. El plan enumera nombres e IDs exactos de contenedores, volúmenes y redes; incluye hash y caducidad de 15 minutos. La ejecución exige el token literal de confirmación y vuelve a verificar que el inventario no cambió. Un proyecto ajeno a Trackvance, un plan alterado, vencido o con recursos cambiados se rechaza. .env se conserva por defecto. No se usa reset para actualizaciones o pruebas sobre la instalación principal.

Para actualizar: terminar runs, respaldar, reconstruir imágenes, aplicar Alembic al iniciar, esperar healthchecks y comparar almacenamiento. Nunca ejecutar down -v sobre la instalación del usuario como parte de un upgrade.

La instalación principal se actualizó a 0.4.0 y Alembic 0007 después de un backup integral verificado. API, worker, web y PostgreSQL quedaron saludables con restart=no; la comprobación conservó los registros previos. Esta actualización no utilizó la instalación principal para pruebas destructivas.

20A. Benchmark reproducible y límites comprobados

scripts/tests/benchmark_cycle.py ejecuta un proyecto Docker aislado con archivos sintéticos, fuentes PostgreSQL/SQL Server reales, materialización canónica, Intake, ReconOps y Sentinel. Registra bytes, filas, duración, throughput, CPU, memoria, I/O, snapshots, plan y éxito/fallo; watchdog detiene su proyecto si supera recursos o tiempo. La progresión exige preflight y termina ante una restricción de recursos. Los tamaños no ejecutados se marcan como tales.

Medición real disponible

El ciclo principal trackvance-bench-22852-894497 terminó PASS. Su fixture nominal de 100 MiB mide 106.194.531 bytes, 50.000 filas y cuatro columnas, con payload determinista variado SHAKE256_URLSAFE_V1. Docker Desktop 29.1.3 dispuso de 16 CPU y 16.326.524.928 bytes de memoria. La duración total fue 79,46 segundos. Las duraciones siguientes son tiempos de pared del runner, incluyendo transporte/espera cuando corresponde; no son microbenchmarks puros del motor.

Operación	Duración medida
Carga archivo origen / destino	1,577 s / 1,306 s.
Intake desde archivo	3,083 s; 16.218 filas/s.
ReconOps desde dos archivos	4,076 s.
Sentinel desde archivo	2,046 s; 24.437 filas/s.
Snapshot PostgreSQL / Intake asociado	2,363 s / 3,112 s.
Snapshot SQL Server / Intake asociado	1,345 s / 3,067 s.

El HWM de proceso fue 812.998.656 bytes en API y 1.051.635.712 en worker; los picos cgroup fueron 1.253.138.432 y 1.224.929.280 respectivamente. El muestreo agregado registró 2.697.222.681 bytes con nueve muestras y CPU máximo agregado de 122,41 %, donde 100 % equivale a un núcleo. Los contenedores no registraron OOM. El almacenamiento temporal tuvo pico observado de 185.340.131 bytes y el crecimiento de storage fue 670.790.434 bytes, con 112 muestras cada 0,2 s. Los muestreos no garantizan capturar todos los picos transitorios; se conservan junto con cgroup/HWM en el JSON.

Representatividad y progresión detenida

El payload variado tiene 2098 caracteres por fila. El archivo produjo Parquet canónico de 79.145.600 bytes. La fuente PostgreSQL leyó 106.144.494 bytes lógicos y produjo 55.099.067 bytes canónicos; SQL Server leyó 105.750.000 y produjo 55.107.251. Se conservaron hashes y linaje de estos snapshots. Las fuentes y el archivo usan generadores deterministas distintos; sus tamaños comprimidos no deben equipararse.

El ensayo anterior trackvance-bench-25400-6b857b también pasó con payload repetido y Parquet SQL de sólo 26.909 bytes; se conserva como antecedente de compresibilidad, no como resultado principal de presión de recursos. La medición variada mejora esa cobertura, pero sigue siendo un perfil de 50.000 filas y cuatro columnas. No establece un máximo universal de Polars ni certifica millones de claves, todas las formas de reglas o un dataset con 100 columnas. Otro perfil requiere otro ensayo reproducible.


Se usaron overrides exclusivos del proyecto temporal: upload de 128 MiB, snapshot de 160 MiB, presupuesto blando del planner de 6 GiB y 1200 segundos en el plan. Los defaults de la instalación no se modificaron. El Recon estimó 5.097.337.488 bytes para ambos inputs; el watchdog no registró una violación.

500 MiB, 1 GiB, 2 GiB y 5 GiB aparecen NOT_RUN_RESOURCE_LIMIT porque la estimación Recon excedía el presupuesto local. No son fallos de ejecución medidos. El máximo comprobado de este perfil es el fixture indicado, con sus overrides y limitaciones. No se proclama completada una matriz de volumen que no se haya ejecutado.

Se conservan los límites operativos por defecto de 10 MiB/upload, 100.000 filas, 100 columnas y 64 MiB de snapshot SQL. Los warnings/rechazos de ExecutionPlanner siguen el presupuesto configurado de memoria/disco y ENGINE_UNAVAILABLE cuando solicita un engine no instalado. La evidencia no justifica elevarlos ni fijar un umbral universal de migración a PySpark. PySpark se recomienda como evaluación de producto ante cargas que superen el presupuesto local, pero su adaptador no se implementa en este ciclo.

21. Arquitectura final de producto

OBJETIVO. El producto final conserva los mismos módulos y contratos funcionales. Evoluciona la entrega de jobs, almacenamiento, fuentes, identidad, observabilidad e infraestructura. No divide Intake, ReconOps o Sentinel en microservicios.



Capacidad	Adaptador / infraestructura objetivo
Despliegue	Docker y Kubernetes, AKS, EKS u OpenShift; Helm para releases.
Metadata	PostgreSQL administrado, backups y recuperación verificados.
Storage interno	S3 o Azure Blob mediante StorageProvider, locators, hashes y retención.
Fuentes	PostgreSQL y SQL Server implementados; S3, Azure Blob, APIs y otros motores futuros mediante DatasetSource.
Jobs	Redis + Celery, reintentos/leases e idempotencia; entrega transaccional definida.
Compute	Polars para cargas estándar, PySpark para grandes volúmenes con paridad certificada.
Identidad	OAuth2/OIDC + SSO con Entra ID, Keycloak u otro IdP; RBAC/org scope propios.
Secretos	Key Vault, AWS Secrets Manager o Vault; referencias fuera de configs de negocio.
Observabilidad	OpenTelemetry, Prometheus, Grafana y logs centralizados.
Infraestructura	Terraform y configuración por ambiente, redes y permisos mínimos.
CI/CD	Quality gates, análisis de dependencias/SAST/secretos/imágenes, SBOM y despliegue controlado.

Pasos de evolución sin cambiar reglas

1. Introducir locator remoto y materialización acotada en un StorageProvider, migrando referencias y validando hashes históricos.
2. Ampliar PostgreSQL/SQL Server con otros conectores DatasetSource, límites, credenciales externas y snapshots reproducibles.
3. Implementar JobQueue Redis/Celery con patrón transaccional/outbox o garantía equivalente; conservar Run y evidencia idempotentes.
4. Añadir ExecutionEngine PySpark, capacidades del planner y pruebas de paridad antes de habilitarlo.
5. Integrar IdP, secretos y observabilidad; aplicar tests de aislamiento y recuperación.
6. Desplegar réplicas API/workers y certificar concurrencia, presión de recursos, backup/restore y upgrades.

Los puertos actuales reducen el área de cambio, pero no certifican esos adapters. La transición requerirá código de infraestructura y migraciones; no deberá reescribir la semántica de reglas, resultados ni trazabilidad.

22. Calidad, pruebas y aceptación

La certificación local ejecuta pytest, Ruff, Mypy, ESLint, TypeScript, Vitest, build frontend, Playwright, smoke API, migraciones PostgreSQL y prueba de persistencia tras restart. El runner crea un proyecto Compose temporal con sus propios volúmenes y elimina únicamente esos datos al terminar.

Verificación	Resultado ejecutado
Alcance 0.4.1	Configuración guiada por esquema y mejora de UX. Sin migraciones ni cambios de semántica backend; compatibilidad histórica obligatoria.
Vitest	119 aprobadas en 13 archivos. Focales App + Datasets 16/16 y ConfigDialog + RuleBuilder + AdvancedRules 34/34 también aprobados durante el desarrollo.
ESLint / TypeScript	PASS.
Build frontend	PASS; bundle JavaScript principal 550,78 kB / 164,59 kB gzip. Advertencia informativa de tamaño, no bloqueante.
Playwright	23 aprobadas con fuentes reales y 1 opt-in limpio aprobado por separado: 24 escenarios distintos. Compose: 19 aprobadas y cinco opt-in cubiertos en sus runners.
Compose / smoke / doctor	PASS: doctor 7/7, smoke API 84/84, migraciones upgrade/downgrade/upgrade y persistencia tras restart.
Conexiones reales	PASS: 62 comprobaciones PostgreSQL/SQL Server, 23 escenarios de navegador, credenciales y logs sin secretos, y restart.
Logout limpio	PASS 1/1: demo sin seed, cierre de sesión, redirección a / y pantalla inicial visible.
GitHub Actions	PASS 6/6 jobs sobre 38a8c7a3: backend, frontend, connections-e2e, compose-e2e, benchmark-smoke y backup-restore-e2e. Workflow https://github.com/eddie-san422/TrackvanceCore/actions/runs/35638817011
pytest backend + scripts	533 aprobadas en 37,36 s. Dos avisos de deprecación Starlette/AnyIO; sin fallos.
Ruff / Mypy	PASS; Mypy revisó 33 archivos fuente.
Contrato y persistencia	OpenAPI y lock actualizados a 0.4.1. Sin endpoints, DTOs o migraciones nuevos; semántica backend sin cambios.
Base 0.4.0	Certificación histórica conservada: 533 tests backend/scripts, 109 Vitest y 24 escenarios Playwright distintos; no sustituye los resultados incrementales 0.4.1.

Certificación incremental 0.4.1

La tabla anterior es la fuente explícita de resultados de esta revisión; ningún éxito se hereda de 0.4.0. En local aprobaron 533 tests backend/scripts, Ruff, Mypy sobre 33 archivos, ESLint, TypeScript, build y 119 tests Vitest en 13 archivos. El bundle principal fue de 550,78 kB / 164,59 kB gzip y conserva un aviso informativo de tamaño.

El ciclo Compose aislado aprobó doctor 7/7, smoke API 84/84, migraciones upgrade/downgrade/upgrade, persistencia tras restart y 19 escenarios Playwright; cinco opt-in se cubrieron en ciclos especializados. El ciclo real de Conexiones aprobó 62 comprobaciones PostgreSQL/SQL Server y 23 escenarios de navegador; el recorrido limpio separado aprobó 1/1, incluido logout, redirección a / e inicio visible. Son 24 escenarios Playwright distintos aprobados; las omisiones no se

cuentan dos veces. No se añadió migración, endpoint ni DTO.

Base certificada de 0.4.0

La ejecución consolidada local aprobó 533 tests pytest en 41,66 s, con dos warnings de deprecación de las dependencias de pruebas. Incluye nueve regresiones nuevas del respaldo/restauración por streaming. Ruff pasó; Mypy comprobó 33 archivos. ESLint, TypeScript y build frontend pasaron; Vitest aprobó 109 tests en 12 archivos. El bundle principal compilado fue de 535,26 kB; su aviso de tamaño no se presenta como fallo de compilación.

La certificación de Conexiones completó 62 comprobaciones con PostgreSQL y SQL Server reales y 23 pruebas Playwright, omitiendo sólo el escenario clean-demo de activación explícita. Ese escenario pasó por separado: en total se probaron 24 escenarios de navegador distintos. El ciclo Compose aprobó 19 pruebas Playwright; sus cinco casos opt-in se cubrieron en las ejecuciones independientes y no se suman como escenarios nuevos.

El ciclo Compose también aprobó smoke API, doctor, migraciones PostgreSQL e integridad después del reinicio. La comparación conservó exactamente 21 tablas, 56 datasets, 70 versiones, 43 runs, 206 artifacts, 1562 relaciones y un adjunto. El drill de recuperación ampliado se describe en la sección 20 y el benchmark medido en 20A. Las pruebas se ejecutaron en proyectos y volúmenes aislados. El resultado de GitHub Actions se informa separadamente; estos éxitos locales no equivalen a un workflow remoto aprobado.

Escenarios de negocio conservados

Escenario	Resultado certificado por tests
Intake 120 filas	110 válidas, 10 con error, aceptación 91,67 %, REJECTED.
Detalle Intake	REQUIRED 4, UNIQUE 4 registros, POSITIVE 2.
Recon 120/110	MATCH 110, SOURCE_ONLY 6, DUPLICATE_SOURCE 4; otras categorías 0; match 91,67 %.
Sentinel baseline	110 filas, 9 checks, 0 fallos, salud 100 %.
Sentinel v2	90 filas, 3 nulls monitorizados, cambio 18,18 %, 4 fallos, salud 55,56 %.
Sentinel v3	90 filas, source_system ausente, cambio 0 %, 1 fallo, salud 88,89 %.
Excepciones	Bloqueo sin validación; Run posterior correcto habilita RESOLVED; cierre administrativo separado.

La base 0.4.0 incluye cinco formatos, hoja Excel, delimitador TXT, JSON anidado simple, esquema embebido Parquet, overrides, identificadores/Todos, selectores de reglas, navegación, dashboard, VALUE_MISMATCH, not_future, schema drift, XLSX/MIME/filename/formula injection, RBAC/CSRF y lineage. La cobertura incremental 0.4.1 comprueba el selector único de identificadores, catálogo de responsables, labels/ayudas/orden/preview de transforms, preview de claves simples y compuestas, multiselect de Sentinel por esquema y regreso al inicio tras logout.

El workflow ci.yml declara checks backend/frontend, migraciones y ciclos Compose/conexiones/recuperación con entornos temporales y evidencia de navegador. Los jobs realmente ejecutados y su resultado se registran en la tabla de validación. Conexiones se prueba con motores reales PostgreSQL y SQL Server, usuarios SELECT, caída/reconexión, versiones, Intake y búsqueda de secretos en logs/metadatos. La ejecución local no equivale a una ejecución remota de GitHub Actions. Security scanning/SBOM y gates de producción permanecen en el objetivo final.

La revisión 0.4.1 quedó certificada en GitHub Actions por el workflow

35638817011, commit 38a8c7a3dd14ecc1c6b730f2a4a98e419707281e:

seis de seis jobs terminaron SUCCESS —backend, frontend, connections-e2e, compose-e2e, benchmark-smoke y backup-restore-e2e—. Este resultado corresponde al mismo código de producto y fuentes documentales usados para la publicación; la incorporación posterior del PDF y del dato de CI es un cierre documental.

Incidencia CI identificada y corrección

El primer workflow 35488396043 aprobó cinco de seis jobs, pero backup falló en Linux. El helper se ejecutaba como usuario trackvance e intentaba escribir sobre un bind del host con permisos 0755 de otro propietario; el sistema devolvió `PermissionError 13`. La causa se reprodujo y se corrigió transportando el tar por stdout/stdin con archivos privados abiertos en el host. No se relajaron permisos del host ni se ejecutó el helper como root. Pasaron 48 pruebas focalizadas, la suite completa de 533 tests y el drill real de recuperación por streaming.

La corrección quedó certificada en GitHub Actions: workflow 35488848150, commit `a03d87ecb051d88abfe57111ae90853f9dcbcf66`, resultado `SUCCESS` en seis de seis jobs: `backend`, `frontend`, `compose-e2e`, `connections-e2e`, `backup-restore-e2e` y `benchmark-smoke`. El job de backup verificó siete artifacts, un secreto y 124 relaciones. Backend aprobó 533 tests, Ruff, Mypy y migraciones; frontend aprobó sus 109 tests, lint, tipos y build. Los escenarios opt-in de navegador se cubrieron en los jobs correspondientes. El benchmark smoke valida el runner con carga pequeña; el volumen local de 100 MiB conserva su certificación independiente. La URL verificable del workflow figura en la tabla de resultados; el fallo inicial permanece documentado como incidencia corregida.

Pendientes explícitos

PySpark, conectores adicionales, Data Delivery, rotación automática de clave maestra, Redis/Celery productivo, OIDC/SSO, Kubernetes/Helm/Terraform, observabilidad distribuida y masking/sensibilidad permanecen fuera de este ciclo. La adquisición asíncrona de grandes volúmenes, timeout duro y agrupación multi-finding no se simulan. Los volúmenes no ejecutados, fallos o gates sin certificar se identifican explícitamente en validación y benchmarks; no se reclasifican como éxitos.

23. Decisiones vigentes y control documental

Decisión	Referencia del repositorio
Monolito modular local y dos modos de arranque	docs/adr/0001-local-prototype.md, antecedente 0.1.
Evidencia v2, actores, artefactos y compatibilidad	docs/adr/0002-evidence-and-artifacts.md.
Semántica observada y reglas declarativas	docs/adr/0003-rule-semantics.md.
Lectores y frontera común de calidad	docs/adr/0004-dataset-readers.md.
Resolución de excepciones validada técnicamente	docs/adr/0005-technical-validation-of-exceptions.md.
Puertos de storage, fuentes, ejecución y cola	docs/adr/0006-architecture-ports.md.
Conexiones, secretos, snapshots y frontera Data Delivery	docs/adr/0007-external-connections.md.
Reglas avanzadas, condiciones, referencias e identidad	docs/adr/0008-advanced-intake-rules.md.
ReconOps configurable, transforms, nulls y agregaciones	docs/adr/0009-configurable-reconciliation.md.
Scheduler Sentinel local y series compatibles	docs/adr/0010-local-sentinel-scheduler.md.
Asignación, SLA, adjuntos y resolución automática	docs/adr/0011-advanced-exception-workflow.md.
Administración local de usuarios y sesiones	docs/adr/0012-local-identity-administration.md.
Backup, restore y reset verificables	docs/adr/0013-local-backup-restore.md.
Benchmark y política de escalado con evidencia	docs/adr/0014-volume-benchmark-policy.md.

Precedencia y cambios de esta revisión

Esta revisión sustituye las afirmaciones de implementación de la edición inicial de 52 páginas. La edición inicial se conserva archivada con su hash, como antecedente. Los diagramas aspiracionales de worker-spark, tablas de organizaciones/roles, librerías no instaladas, exports CSV principales y endpoints futuros ya no se presentan como realidad operativa.

Se actualizan arquitectura local/final, esquema real de 21 tablas, API generada, cinco lectores, Conexiones PostgreSQL/SQL Server, SecretStore, snapshots, profiling exacto, reglas avanzadas, referencias, ReconOps configurable, Sentinel programado, excepciones con SLA y cierre verificado, usuarios/RBAC, operación, benchmarks y límites comprobados. Se preservan Parquet canónico, manifests v2, Excel, cockpit, auditoría, persistencia Docker y arranque manual.

El código y OpenAPI determinan el contrato ejecutable. Un cambio posterior de semántica requiere ADR, pruebas, actualización de esta fuente y del PDF; un cambio de base de datos requiere Alembic nuevo. Las versiones de configs/manifests/métricas se gestionan separadas de la versión del producto.

Registro

Fecha	Revisión	Descripción
10-09-2026	Especificación v1.1 inicial	Diseño y objetivo de producto.
16-09-2026	v1.1, implementación 0.3.0	Consolidación del estado real, fronteras de infraestructura y validación local.
19-09-2026	v1.1, evolución Conexiones	PostgreSQL, SQL Server, secretos cifrados, snapshots y pruebas con motores reales.
19-09-2026	v1.1, implementación 0.4.0	Maduración funcional del roadmap local; resultados y límites según evidencia de esta revisión.
21-09-2026	v1.1, implementación 0.4.1	Configuración guiada por esquema, previews informativos, catálogo de responsables y cierre de sesión corregido; contratos del motor sin cambios.

La fuente editable y el generador portable acompañan al PDF en docs/specification; la copia oficial se conserva en Documentación. README, arquitectura, catálogo, ADRs, OpenAPI y documentación de operación complementan esta especificación con comandos y contratos de detalle. Los resultados de validación son una entrada explícita del generador; el documento no reutiliza números de una entrega anterior como certificación de 0.4.1.